

TỔNG QUAN ĐỒ ÁN • MÔ HÌNH TƯƠNG TÁC DỮ LIỆU TRỰC QUAN

Phân Tích Rủi Ro Tín Dụng & Khả Năng Vỡ Nợ Khách Hàng Cá Nhân

Credit Risk Analytics & Default Prediction Dashboard

Dataset: Home Credit Default Risk (Kaggle) | Mục tiêu điểm: 9.5/10 (A+)
Dashboard: Power BI / Streamlit + Plotly | Model: Logistic Regression + XGBoost

1. Bối cảnh & Bài toán kinh doanh

Trong hoạt động cho vay tiêu dùng, việc đánh giá sai rủi ro tín dụng dẫn đến hai loại tổn thất: **duyệt nhầm khách hàng xấu** (nợ xấu, mất vốn) và **từ chối oan khách hàng tốt** (mất doanh thu). Đề án xây dựng một hệ thống phân tích và dự báo rủi ro tín dụng khách hàng cá nhân, đóng vai trò như một **Data Analyst / Risk Analyst** trình bày kết quả cho bộ phận quản trị rủi ro của tổ chức tín dụng.

Mục tiêu cốt lõi: Xây dựng pipeline hoàn chỉnh từ dữ liệu thô → mô hình dự báo xác suất vỡ nợ (Probability of Default) → hệ thống điểm tín dụng (Credit Score) → dashboard trực quan hỗ trợ ra quyết định duyệt vay theo thời gian thực.

Điểm khác biệt so với đồ án thông thường

Credit Scoring 300-850

Expected Loss / Lợi nhuận

XGBoost + SHAP

Xử lý Imbalanced Data

Fairness Check

What-if Simulator

Storytelling 3 lớp

2. Dataset

Bảng dữ liệu	Nội dung	Vai trò
application_train/test	Hồ sơ vay chính (~307,000 dòng): thu nhập, nghề nghiệp, tình trạng gia đình, loại vay...	Bảng trung tâm
bureau	Lịch sử tín dụng của khách hàng tại các tổ chức tín dụng khác	Join theo SK_ID_CURR
bureau_balance	Lịch sử trả nợ hàng tháng theo từng khoản vay bên ngoài	Aggregate → bureau
previous_application	Lịch sử các khoản vay trước đó tại chính tổ chức	Join theo SK_ID_CURR
installments_payments	Lịch sử trả góp thực tế so với kế hoạch	Feature hành vi trả nợ
credit_card_balance / POS_CASH_balance	Số dư thẻ tín dụng & khoản vay trả góp theo tháng	Feature bổ sung

Nguồn: Kaggle — Home Credit Default Risk. Thỏa mãn yêu cầu $\geq 5,000$ dòng và ≥ 3 bảng liên kết qua khóa chính SK_ID_CURR.

3. Pipeline tổng thể



3.1 Thu thập & Tiền xử lý

- Join/Merge các bảng theo SK_ID_CURR, aggregate bảng phụ (mean/max/count theo nhóm)
- Xử lý missing values, outlier (VD: DAYS_EMPLOYED có giá trị bất thường 365243)
- Tạo calculated fields: DTI (Debt-to-Income), tỷ lệ Credit/Annuity, số năm làm việc, nhóm tuổi, số lần trễ hạn trong quá khứ

3.2 Khám phá dữ liệu (EDA)

- Phân phối thu nhập theo Target (default/non-default)
- Tỷ lệ vỡ nợ theo nhóm tuổi, nghề nghiệp, loại hợp đồng vay
- Correlation heatmap giữa các biến số & Boxplot outlier trước/sau xử lý

3.3 Dashboard trực quan hóa tương tác

- Công cụ:** Power BI hoặc Streamlit + Plotly
- 8+ loại biểu đồ:** Bar, Line, Pie/Donut, Scatter, Heatmap, Treemap, Boxplot, và **Map** (phân bố rủi ro theo vùng)
- Tính năng:** Filter nhiều cấp, Drill-down, Tooltip, Cross-filtering giữa các biểu đồ
- Điểm nhấn:** What-if Simulator — nhập thông tin khách hàng, hệ thống trả về risk score tức thì

3.4 Insight & Mô hình dự báo

- Logistic Regression (baseline bắt buộc theo đề) + XGBoost/LightGBM (nâng cao)
- Xử lý mất cân bằng dữ liệu bằng SMOTE / class weighting
- SHAP values giải thích đóng góp từng đặc trưng vào dự đoán
- Quy đổi xác suất vỡ nợ → Credit Score (thang 300-850) & phân lớp Risk Tier (Low/Medium/High)

4. Các điểm nhấn nâng cao (mục tiêu vượt barem)

① **Credit Scoring System** — Quy đổi xác suất vỡ nợ (log-odds) thành thang điểm tín dụng chuẩn ngành (300–850, tương tự FICO), thay vì chỉ xuất nhãn 0/1.

② **Expected Loss & Phân tích lợi nhuận** — Ước tính nếu ngân hàng áp dụng mô hình, giảm bao nhiêu % nợ xấu / tăng bao nhiêu % lợi nhuận cho vay — gắn kết quả kỹ thuật với giá trị kinh doanh cụ thể.

③ **XGBoost/LightGBM + SHAP** — So sánh với Logistic Regression baseline, dùng SHAP để giải thích model ở mức từng khách hàng (explainable AI), thể hiện chiều sâu kỹ thuật khi vấn đáp.

④ **Xử lý Imbalanced Data** — Chủ động phát hiện và xử lý mất cân bằng lớp (tỷ lệ vỡ nợ thực tế thường chỉ 5–8%) bằng SMOTE/class weighting, tránh đánh giá sai lệch bằng accuracy.

⑤ **Fairness Check & Model Validation** — Kiểm tra model có thiên lệch (bias) theo giới tính/độ tuổi không; phân tích trade-off giữa False Positive và False Negative theo các ngưỡng (threshold) khác nhau, gắn với chi phí kinh doanh thực tế.

5. Đối chiếu với Barem chấm điểm (10đ)

Hạng mục Barem	Điểm	Cách đổ án đáp ứng / vượt yêu cầu
Thu thập & Tiền xử lý dữ liệu	2.5	Multi-table Home Credit, xử lý missing/outlier triệt để, calculated fields có ý nghĩa nghiệp vụ (DTI, tỷ lệ vay/thu nhập)
Thiết kế & Xây dựng Dashboard	3.5	8+ loại biểu đồ, bản đồ rủi ro theo vùng, filter/drill-down/cross-filtering, + What-if Simulator
Phân tích Insight & Dự báo	2.0	Logistic Regression đúng yêu cầu, + XGBoost/SHAP, Credit Scoring, Expected Loss
Báo cáo khoa học & Demo	2.0	Chuẩn IEEE, storytelling 3 lớp (Overview→Diagnostic→Prescriptive), demo đóng vai Risk Analyst

Tổng: 10.0 điểm barem — các điểm nhấn (mục 4) nhằm đảm bảo phần vấn đáp giữ trọn điểm, không bị trừ.

Lưu ý về vấn đáp: Theo barem, điểm có thể bị trừ tối đa 4.0 nếu nhóm không hiểu rõ source code hoặc logic tính toán. Do đó mỗi thành viên cần nắm vững toàn bộ pipeline, không chỉ riêng phần mình phụ trách (chi tiết phân công xem file *phan-cong-nhiem-vu.md*).

6. Công nghệ sử dụng

Nhóm	Công cụ / Thư viện
Ngôn ngữ & xử lý dữ liệu	Python (Pandas, NumPy)
Trực quan hóa tĩnh (EDA)	Matplotlib, Seaborn
Machine Learning	Scikit-learn (Logistic Regression), XGBoost/LightGBM, imbalanced-learn (SMOTE), SHAP
Dashboard tương tác	Power BI hoặc Streamlit + Plotly
Báo cáo & thuyết trình	Word/LaTeX (chuẩn IEEE), PowerPoint/Slide